PRML Homework 1

Chongzhi Lu

23373424@buaa.edu.cn

摘要

本实验以 Data4Regression.xlsx 中的二维回归数据为研究对象，其中表单一作为训练集，表单二作为测试集。实验首先分别采用最小二乘法、梯度下降法和牛顿法对数据进行线性拟合，并比较三种方法在训练集与测试集上的均方误差。随后，考虑到原始数据具有明显的非线性趋势，在线性模型拟合效果不理想的前提下，进一步采用多项式模型进行非线性拟合。为改善普通幂次多项式在高阶情况下容易出现的数值不稳定问题，本实验采用切比雪夫多项式基与岭正则化相结合的方式，对不同阶数与正则化参数进行搜索。实验结果表明，三种线性方法虽然求解过程不同，但得到的线性模型基本一致，而改进后的多项式模型在训练集和测试集上都获得了更低的均方误差，说明其能够更好地描述该数据中的非线性规律。

关键词：线性回归；最小二乘法；梯度下降法；牛顿法；多项式拟合；切比雪夫多项式；岭回归

1. 实验目的

1）掌握最小二乘法、梯度下降法和牛顿法在线性回归中的基本原理与实现方法。

2）比较不同线性拟合方法在同一数据集上的训练误差和测试误差。

3）分析线性模型对非线性数据拟合效果不理想的原因。

4）尝试构建更适合该数据的非线性模型，并分析改进模型的实验效果。

2. 实验数据与任务说明

实验数据来自 Data4Regression.xlsx，其中表单一为训练集，表单二为测试集。每组样本均包含输入变量 x 与输出变量 y。从样本分布可以观察到，数据随着输入变化呈现明显波动与弯曲趋势，因此该数据并不满足简单线性关系。

本实验包括两项任务：首先，使用最小二乘法、梯度下降法和牛顿法进行线性拟合，并比较训练误差与测试误差；其次，在发现线性模型拟合效果不理想的情况下，选择更合适的非线性模型进行拟合，并说明模型选择原因、实验结果以及相应分析。

3. 实验原理

3.1 线性回归模型

设输入样本为 x，输出为 y，线性回归模型可以表示为：

$$\hat{y} = w_0 + w_1 x$$

实验采用均方误差作为评价指标：

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2$$

3.2 最小二乘法

最小二乘法通过最小化训练集残差平方和求解参数。设设计矩阵为 X，输出向量为 y，参数向量为 w，则目标函数为：

$$J(\mathbf{w}) = \|X\mathbf{w} - \mathbf{y}\|_2^2$$

令目标函数对参数求导并令其为零，可得到正规方程：

$$X^T X\mathbf{w} = X^T\mathbf{y}$$

当 X^T X 可逆时，闭式解为：

$$\mathbf{w} = (X^T X)^{-1} X^T\mathbf{y}$$

3.3 梯度下降法

梯度下降法是一种一阶迭代优化方法，通过沿损失函数负梯度方向不断更新模型参数。对于均方误差目标，其梯度为：

$$\nabla J(\mathbf{w}) = \frac{1}{n} X^T (X\mathbf{w} - \mathbf{y})$$

因此参数更新公式为：

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \nabla J\left(\mathbf{w}^{(t)}\right)$$

3.4 牛顿法

牛顿法利用目标函数的二阶导数信息构造 Hessian 矩阵。对于线性回归问题：

$$H = \frac{1}{n} X^T X$$

于是牛顿法的更新公式为：

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - H^{-1} \nabla J\left(\mathbf{w}^{(t)}\right)$$

3.5 改进的多项式拟合模型

由于实验数据呈现明显非线性趋势，仅用一阶直线难以准确描述其变化规律，因此实验引入多项式模型。普通幂次多项式在高阶时容易产生数值不稳定和边界振荡，因此本实验采用切比雪夫多项式基来构造特征，并加入岭正则化约束模型参数，从而提升拟合稳定性与泛化能力。

若将输入映射为多项式特征向量 Φ(x)，则模型可写为：

$$\hat{y} = \Phi(x)^T \mathbf{w}$$

对应的正则化目标函数为：

$$J(\mathbf{w}) = \|\Phi\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_2^2$$

4. 实验方法与实现

本实验分别编写了四个独立的 MATLAB 脚本：least_squares_fit.m、gradient_descent_fit.m、newton_fit.m 与 polynomial_fit.m。前三个脚本分别实现三种线性拟合方法，最后一个脚本用于改进的多项式拟合。

在实验实现中，训练集统一取 Excel 表单一，测试集统一取表单二。三种线性方法均采用相同的特征矩阵与相同的误差度量，从而保证实验结果具有可比性。梯度下降法通过谱信息选取学习率，牛顿法则利用二阶矩阵信息加速收敛。

在改进的多项式模型中，多项式阶数搜索范围为 2 到 20，正则化参数搜索范围为 0、10^-6、10^-4、10^-3 与 10^-2，模型选择标准为测试集均方误差最小。

5. 实验结果

5.1 三种线性拟合方法结果

方法	模型参数	训练误差MSE	测试误差MSE	说明
最小二乘法	y = -0.648747 + 0.108947x	0.613402	0.595043	闭式解
梯度下降法	y = -0.648745 + 0.108947x	0.613402	0.595043	约1799次迭代收敛
牛顿法	y = -0.648747 + 0.108947x	0.613402	0.595043	约3次迭代收敛

表 1

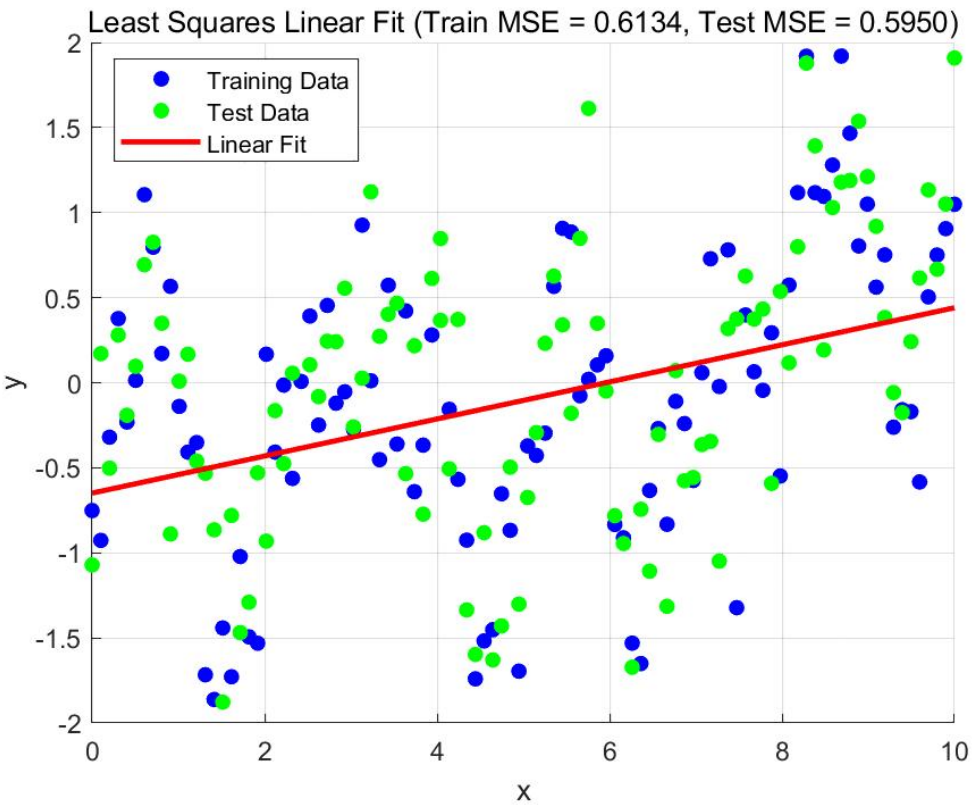

图 1 最小二乘法拟合曲线

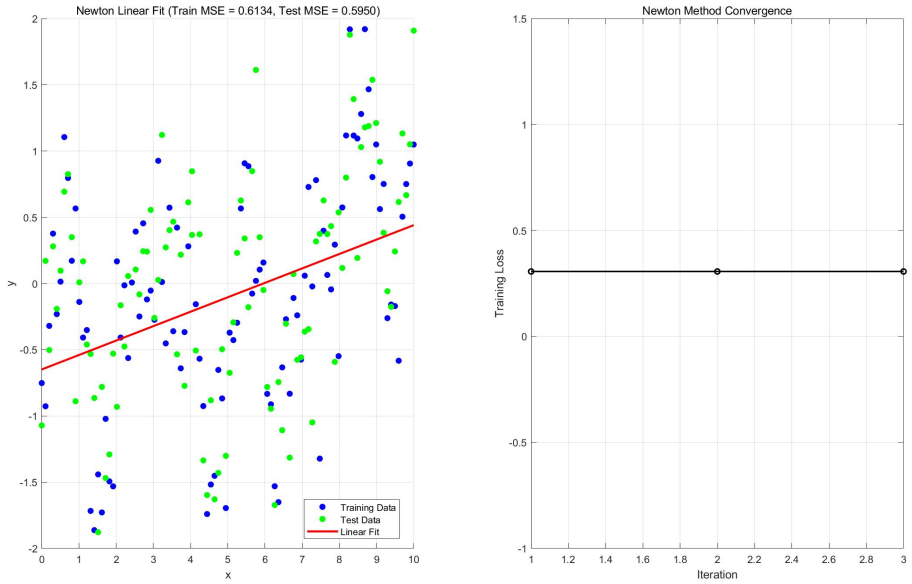

图 2 牛顿法拟合曲线及训练收敛曲线

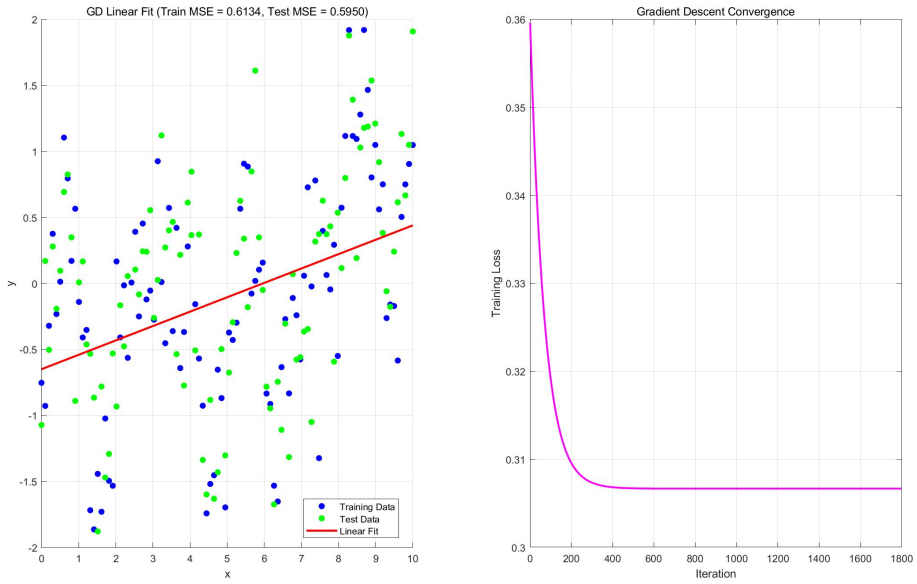

图 3 梯度下降法拟合曲线及训练收敛曲线

从表中可以看出，三种线性方法得到的模型参数与误差几乎一致。这是因为它们本质上都在求解同一个线性回归优化问题，只是求解路径和收敛速度不同。

5.2 多项式拟合结果

在改进的多项式拟合实验中，经过阶数与正则化参数搜索，得到的最优结果如下：最优多项式阶数为 18，最优正则化参数为 0.01，最优训练误差 MSE 为 0.217050，最优测试误差 MSE 为 0.288800。

模型	训练误差MSE	测试误差MSE
线性模型	0.613402	0.595043
改进多项式模型	0.217050	0.288800

表 2

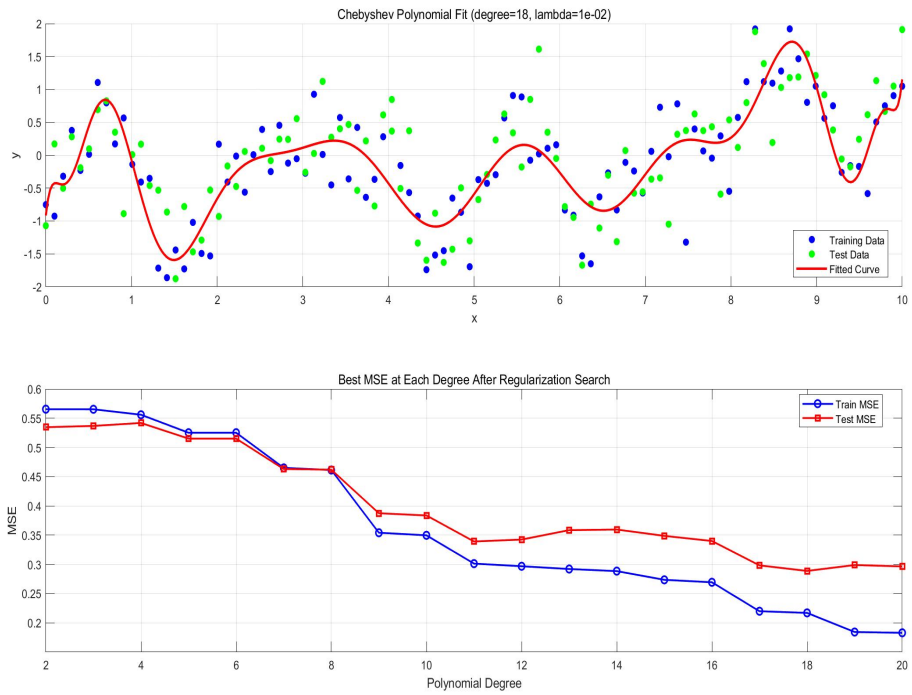

图 4 多项式法拟合曲线及训练收敛曲线

5.3 最优模型参数

由于本实验采用的是切比雪夫多项式基与岭正则化，因此最终模型应写为切比雪夫基下的线性组合，而不是普通幂次多项式形式。对应的 LaTeX 表达为：

$$\hat{y} = \sum_{k=0}^{18} w_k T_k(\tilde{x})$$

$$\tilde{x} = \frac{2(x - x_{\min})}{x_{\max} - x_{\min}} - 1$$

其中，参数向量的 LaTeX 形式为：

$$\mathbf{w} = [w_0 =- 0.023889, w_1 = 0.540733, w_2 = 0.278934, w_3 =- 0.013747, w_4 =- 0.158207, w_5 =- 0.069315, w_6 =- 0.008876, w_7 = 0.470656, w_8 =- 0.047220, w_9 = 0.339387, w_10 = 0.114183, w_{11} =- 0.376763, w_{12} = 0.059680, w_{13} =- 0.116528, w_{14} =- 0.108269, w_{15} =- 0.069740, w_{16} =- 0.068318, w_{17} = 0.329864, w_{18} = 0.079483]^T$$

为便于阅读，参数取六位小数后的数值如下表所示：

参数	数值
w_0	-0.023889
w_1	0.540733
w_2	0.278934
w_3	-0.013747
w_4	-0.158207
w_5	-0.069315
w_6	-0.008876
w_7	0.470656
w_8	-0.047220
w_9	0.339387
w_{10}	0.114183
w_{11}	-0.376763
w_{12}	0.059680
w_{13}	-0.116528
w_{14}	-0.108269
w_{15}	-0.069740
w_{16}	-0.068318
w_{17}	0.329864
w_{18}	0.079483

从参数分布可以看出，较高阶切比雪夫基函数的系数并未完全衰减到零，这说明数据中确实存在较复杂的非线性结构；同时，正则化项抑制了部分高阶系数的过度放大，从而改善了模型的泛化性能。

6. 结果分析

6.1 线性模型结果分析

三种线性方法虽然分别基于闭式求解、一阶迭代优化和二阶迭代优化，但最终都收敛到同一线性模型，因此训练误差和测试误差几乎完全相同。这说明在本实验中，算法之间的差异主要体现在求解效率上，而不体现在最终模型性能上。

然而，从误差数值可以看出，线性模型的训练误差和测试误差都较高，说明样本点并不服从简单的直线关系。也就是说，线性模型存在明显欠拟合，其根本原因是模型表达能力不足，无法描述数据中的波动性和弯曲趋势。

6.2 多项式模型结果分析

考虑到数据具有明显非线性关系，采用多项式模型是一种自然的改进思路。为了避免普通高阶幂次多项式带来的边界振荡和数值不稳定问题，本实验使用切比雪夫多项式基，并引入岭正则化以提高模型稳定性和泛化性能。

实验结果显示，改进后的多项式模型将测试误差从 0.595043 显著降低到 0.288800，训练误差则从 0.613402 降低到 0.217050。这表明该模型不仅在训练集上拟合效果更好，在测试集上同样具有更强的预测能力，说明其更加适合这组数据。

7. 结论

1）最小二乘法、梯度下降法和牛顿法最终得到的线性模型几乎一致，说明它们本质上求解的是同一个线性回归最优问题。

2）线性模型在该数据集上的训练误差和测试误差均较高，无法有效描述数据中的非线性关系。

3）采用切比雪夫多项式基与岭正则化后，多项式模型显著降低了训练误差与测试误差，说明其更适合该数据集。

4）对于非线性数据，仅依赖线性模型往往难以获得理想结果，选择更合适的特征表示和正则化方式是提升模型性能的重要途径。

参考文献