PRML Homework 2

Chongzhi Lu

23373424@buaa.edu.cn

摘要

本实验针对目录中程序生成的三维双月形分类数据集开展监督学习研究。按照题目要求，训练集由同分布生成的 1000 个样本组成，其中 C0 与 C1 各 500 个；测试集由 500 个样本组成，其中两类各 250 个。实验分别比较了单棵决策树、AdaBoost 集成决策树以及支持向量机三类方法的分类性能，并在支持向量机中考察了 linear、polynomial、RBF 与 sigmoid 四种核函数。为保证比较公平，实验对超参数采用五折交叉验证选择。结果表明，面对该类具有明显非线性边界的三维数据，非线性 SVM 的表现最优，其中 RBF 核在测试集上达到 97.8% 的准确率；AdaBoost + Decision Tree 以 97.6% 的准确率紧随其后；单棵决策树虽能处理非线性边界，但泛化能力略弱；线性核 SVM 因只能学习线性分割超平面，表现显著落后。实验说明，对于带噪声的非线性流形分类问题，能够构造平滑非线性决策边界的模型更具优势。

关键词：决策树；AdaBoost；支持向量机；核函数；三维双月数据；混淆矩阵

1. 实验目的

1）掌握三维非线性分类数据集的构造方式与基本性质。

2）比较 Decision Tree、AdaBoost + Decision Tree 与 SVM 在同一数据集上的分类性能。

3）分析不同 SVM 核函数对非线性分类问题的影响。

4）结合测试集准确率与混淆矩阵，讨论不同算法表现差异的原因。

2. 实验数据与任务说明

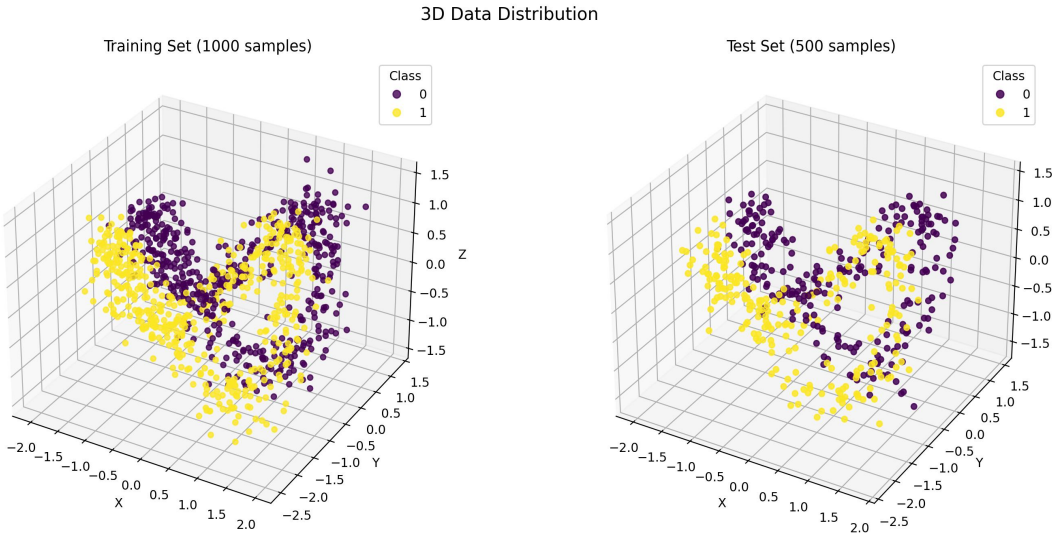

图 1 训练集与测试集的三维数据分布

原始脚本 [3D数据集.py] 通过参数方程构造一个三维 make-moons 风格数据集。设参数 t 在 [0, 2π] 上均匀取值，则一类样本由 (1.5cos t, sin t, sin 2t) 给出，另一类样本由其镜像与平移变换 (−1.5cos t, sin t −1, −sin 2t) 给出，随后叠加高斯噪声。因此，两类样本在三维空间中形成相互交错的非线性流形。

需要特别指出的是，数据生成函数中的参数 n_samples 表示“每一类”的样本数。因此，为满足题目中“训练集共 1000 个样本、测试集共 500 个样本”的要求，本实验取训练集参数 n_samples=500，测试集参数 n_samples=250，且两次生成均使用 noise=0.2。

实验任务包括：使用 Decision Tree、AdaBoost + Decision Tree 与 SVM 对训练集进行学习，再利用新生成的同分布测试集进行评估；其中 SVM 至少考察三种不同核函数，并比较模型性能差异。

3. 算法原理

3.1 Decision Tree

决策树通过递归地选择特征划分规则，将样本空间划分为若干区域，并在叶节点给出类别预测。分类任务中常用的信息增益或基尼指数衡量划分优劣。若当前样本集合为 D，其经验熵为：

$$H(D)=-\sum_{k=1}^{K} p_k \log p_k$$

当按属性 A 划分后，信息增益为：

$$\mathrm{Gain(D, A) = H(D) - \sum_{v} \frac{|D^v|}{|D|} H(D^v)}$$

实验中通过交叉验证选择树的最大深度、叶节点最小样本数等参数。决策树能够拟合非线性边界，但其划分本质上是轴对齐的分段切分，因此面对平滑弯曲边界时容易形成“阶梯状”近似。

3.2 AdaBoost + Decision Tree

AdaBoost 是一种提升方法，其核心思想是将若干个弱分类器加权组合成强分类器。在第 m 轮迭代中，算法根据当前样本权重训练基分类器 h_m(x)，并计算加权误差：

$$\varepsilon_m=\sum_{i=1}^{N} w_i^{(m)} I(y_i \neq \mathrm{h}_m(x_i))$$

随后得到分类器权重：

$$\alpha_m=\frac{1}{2}\ln\frac{1-\varepsilon_m}{\varepsilon_m}$$

并更新样本权重，使前一轮被误分类的样本在下一轮获得更大关注：

$$w_i^{(m+1)} \propto w_i^{(m)} \exp\left(-\alpha_m y_i \mathrm{h}_m(x_i)\right)$$

本实验以浅层决策树作为弱学习器。这样既保留了树模型处理非线性边界的能力，又通过集成降低了单棵树对噪声的敏感性。

3.3 Support Vector Machine

支持向量机通过最大化分类间隔来构造判别超平面。软间隔 SVM 的优化目标为：

$$\min_{w,b,\xi} \frac{1}{2}\|w\|^2+C\sum_{i=1}^{N}\xi_i$$

$$\mathrm{s.t.}\ y_i(w^T x_i + b) \geq 1 - \xi_i,\ \xi_i \geq 0$$

对于线性不可分问题，可通过核技巧将输入映射到高维特征空间，只需计算核函数$K(x_i, x_j) = \phi(x_i)^T\phi(x_j)$。本实验考察四类核函数：

$$Linear: K(x,z)=x^Tz$$

$$Polynomial: K(x,z)=(\gamma x^Tz+r)^d$$

$$RBF: K(x,z)=\exp(-\gamma\|x-z\|^2)$$

$$Sigmoid: K(x,z)=\tanh(\gamma x^Tz+r)$$

其中，线性核适用于近似线性可分问题；多项式核可表达有限阶特征交互；RBF 核能够形成局部而平滑的非线性边界；sigmoid 核具有类似神经元激活的非线性映射特征。由于 SVM 对特征尺度较敏感，本实验在 SVM 前统一进行标准化。

4. 实验方法与实现

实验脚本为 evaluate_models.py。训练集和测试集均直接调用原始数据生成逻辑，只是使用不同随机种子，从而保证测试样本与训练样本独立但同分布。为避免偶然参数选择带来的偏差，所有模型均使用五折分层交叉验证选择超参数。

具体设置如下：Decision Tree 搜索 criterion、max_depth、min_samples_split 与 min_samples_leaf；AdaBoost 搜索基学习器深度、弱分类器数量与学习率；SVM 分别对 linear、poly、rbf 与 sigmoid 核搜索惩罚参数 C 及核相关参数。最终在独立测试集上报告 Accuracy、Macro-F1 与混淆矩阵。

5. 实验结果

5.1 各模型总体性能对比

模型	交叉验证准确率	测试准确率	Macro-F1
SVM (rbf)	0.9830	0.9780	0.9780
SVM (sigmoid)	0.9490	0.9780	0.9780
AdaBoost + Decision Tree	0.9810	0.9760	0.9760
SVM (poly)	0.9800	0.9760	0.9760
Decision Tree	0.9580	0.9520	0.9520
SVM (linear)	0.6780	0.6820	0.6820

表 1 各模型总体性能对比

由表中结果可见，RBF 核 SVM 在测试集上取得最高准确率 0.9780；sigmoid 核 SVM 在本次数据划分下达到同样的测试准确率，但其交叉验证准确率略低，说

明其稳定性稍弱。AdaBoost + Decision Tree 和多项式核 SVM 紧随其后，而线性核 SVM 明显不适合该数据。

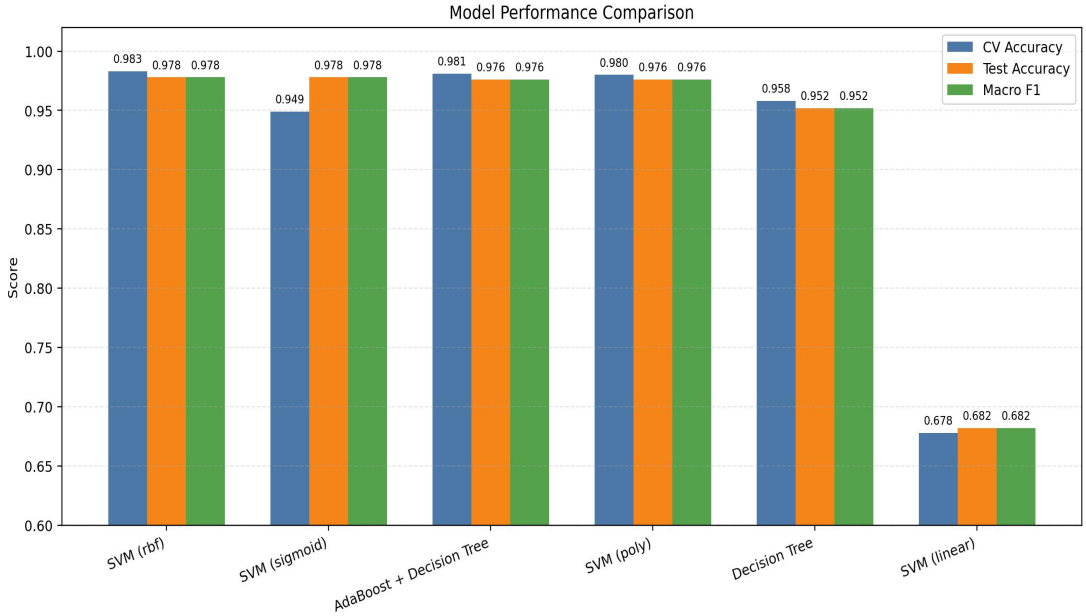

图 2 各模型交叉验证准确率、测试准确率与 Macro-F1 对比

5.2 最优参数

模型	最优参数
SVM (rbf)	{"svc__C": 10, "svc__gamma": "scale"}
SVM (sigmoid)	{"svc__C": 100, "svc__coef0": -1.0, "svc__gamma": 0.1}
AdaBoost + Decision Tree	{"estimator__max_depth": 3, "learning_rate": 0.5, "n_estimators": 200}
SVM (poly)	{"svc__C": 1, "svc__coef0": 1.0, "svc__degree": 4, "svc__gamma": "scale"}
Decision Tree	{"criterion": "entropy", "max_depth": null, "min_samples_leaf": 1, "min_samples_split": 2}
SVM (linear)	{"svc__C": 1}

表 2 各模型最优参数

5.3 混淆矩阵

混淆矩阵能够更细致地反映各模型在两类样本上的分类情况。

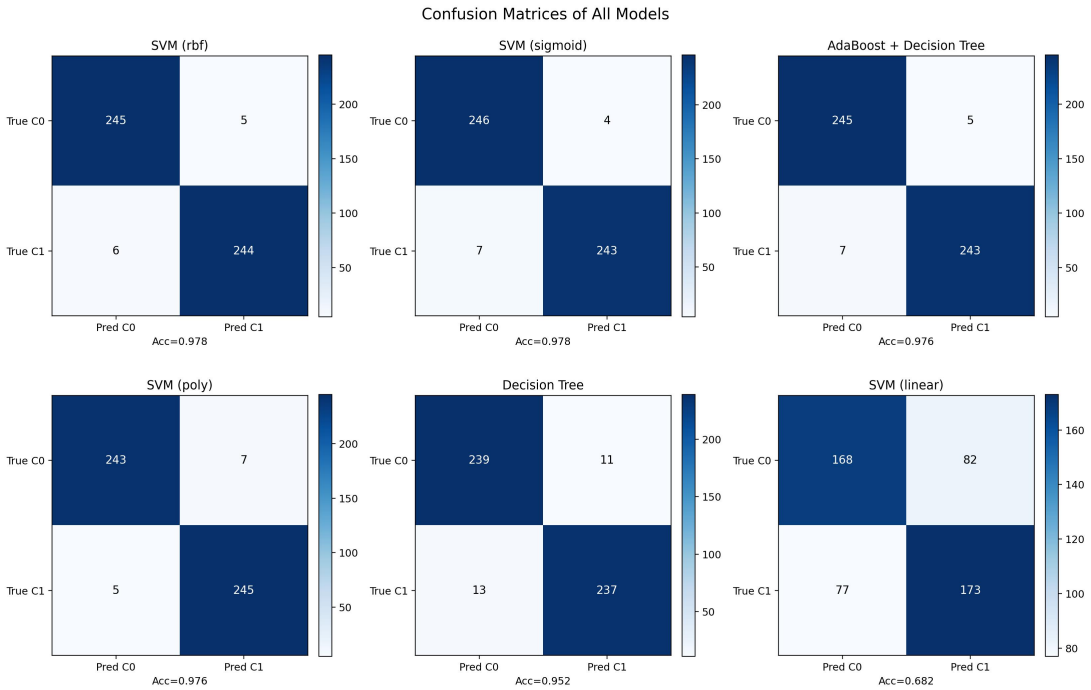

图 3 各模型混淆矩阵总览

6. 结果分析

6.1 为什么非线性 SVM 表现更好

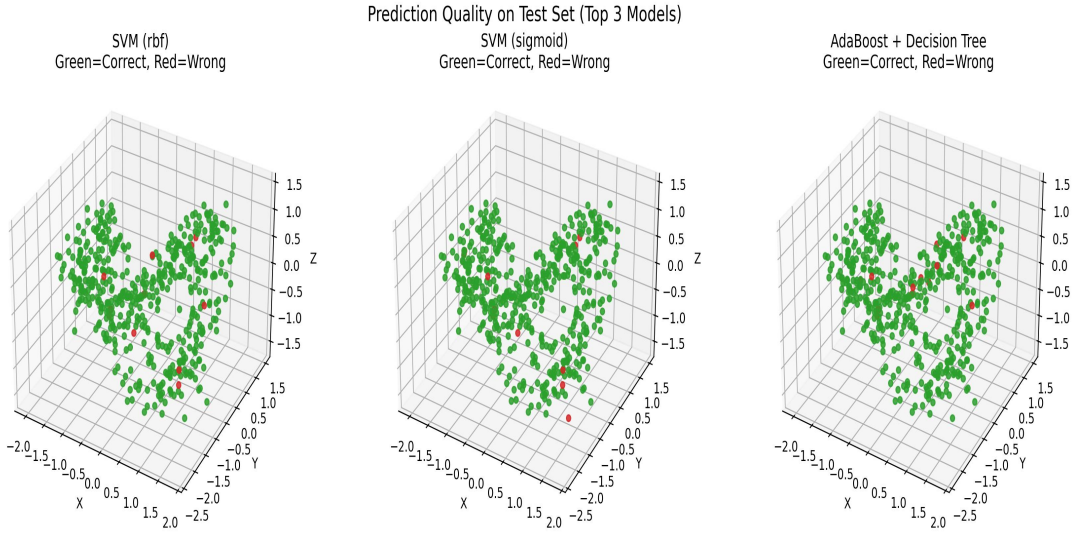

图 4 前三名模型在测试集上的预测正确与错误分布

该三维数据集虽然只有 3 个特征维度，但类边界并不是简单平面，而是弯曲、缠绕的非线性结构。RBF 核能够在特征空间中构造局部、平滑且灵活的决策边界，因此最适合描述双月型流形；多项式核同样具备表达曲线边界的能力，因此性能也很高。这说明对该问题而言，模型是否能够表达复杂非线性边界，是决定最终性能的关键。

6.2 为什么 AdaBoost + Decision Tree 优于单棵 Decision Tree

单棵决策树已经可以处理非线性问题，因此其结果明显优于线性核 SVM。但单棵树容易对局部噪声和样本扰动敏感，泛化性能有限。AdaBoost 通过多轮迭代不断聚焦前一轮难分样本，并将多个弱学习器组合起来，从而显著提升边

界拟合能力和整体稳定性。因此，AdaBoost + Decision Tree 在测试集上的准确率由 0.9520 提升至 0.9760。

6.3 为什么线性核 SVM 表现最差

线性核 SVM 只能学习单个线性超平面，而双月结构本质上并不线性可分。无论在二维还是扩展到三维后，类别之间仍呈弯曲交错分布。因此线性模型无法有效刻画真实边界，导致大量样本被错误划分，其混淆矩阵中两类的误分数量都明显偏高。

7. 结论

1）在该 3D 双月数据集上，非线性分类方法整体优于线性分类方法。

2）RBF 核 SVM 取得最优结果，测试准确率达到 0.9780，说明其最适合刻画该数据的非线性边界。

3）AdaBoost + Decision Tree 显著优于单棵决策树，体现了集成学习在提升泛化能力方面的优势。

4）线性核 SVM 因模型表达能力不足而表现最差，进一步说明该问题并非线性可分问题。

5）对于这类带噪声且边界平滑弯曲的分类任务，具有非线性映射能力且泛化能力较强的模型更具优势。